PISCINE MAKERS · EMBEDDING LAB

Semantic Agent Engine

Une mémoire qui sait ce qui a été décidé,
et ce qui est encore vrai.

Architecture mise à jour · Jonathan Chayna · octobre 2026

L'idée en une minute

En réunion, tout n'est pas décidé tout de suite : on propose, on hésite, on change d'avis. Une recherche classique retrouve les phrases qui **se ressemblent**, mais pas forcément celle qui est **encore vraie aujourd'hui**. Ce moteur lit chaque échange, le range dans une mémoire organisée, relie les informations entre elles (« ceci remplace cela »), puis retrouve la bonne version, avec sa preuve.

Il comprend

Une proposition n'est pas une décision. « On pourrait peut-être… » ne déclenche rien ; « c'est validé », oui.

Il se souvient

Chaque information garde sa date, la personne qui l'a dite et la phrase exacte d'origine.

Il propose, il n'exécute pas

E-mails, tâches, événements : toujours des brouillons à confirmer. Aucune adresse n'est inventée.

L'image à retenir : un atelier bien rangé

On ne retourne pas tout l'atelier pour trouver une clé à molette : chaque outil est rangé au bon endroit **dès son arrivée**. Ici, chaque information est rangée à côté de celles qui lui sont liées, au moment où elle arrive. Retrouver devient rapide, et quand une information change, la mémoire se met à jour au lieu de s'empiler.

Un seul cœur, deux usages

Réunions et messages

Le sujet de la piscine : retrouver une décision, qui s'est engagé, ce qui a changé entre deux réunions, préparer un dossier ou un brouillon d'e-mail.

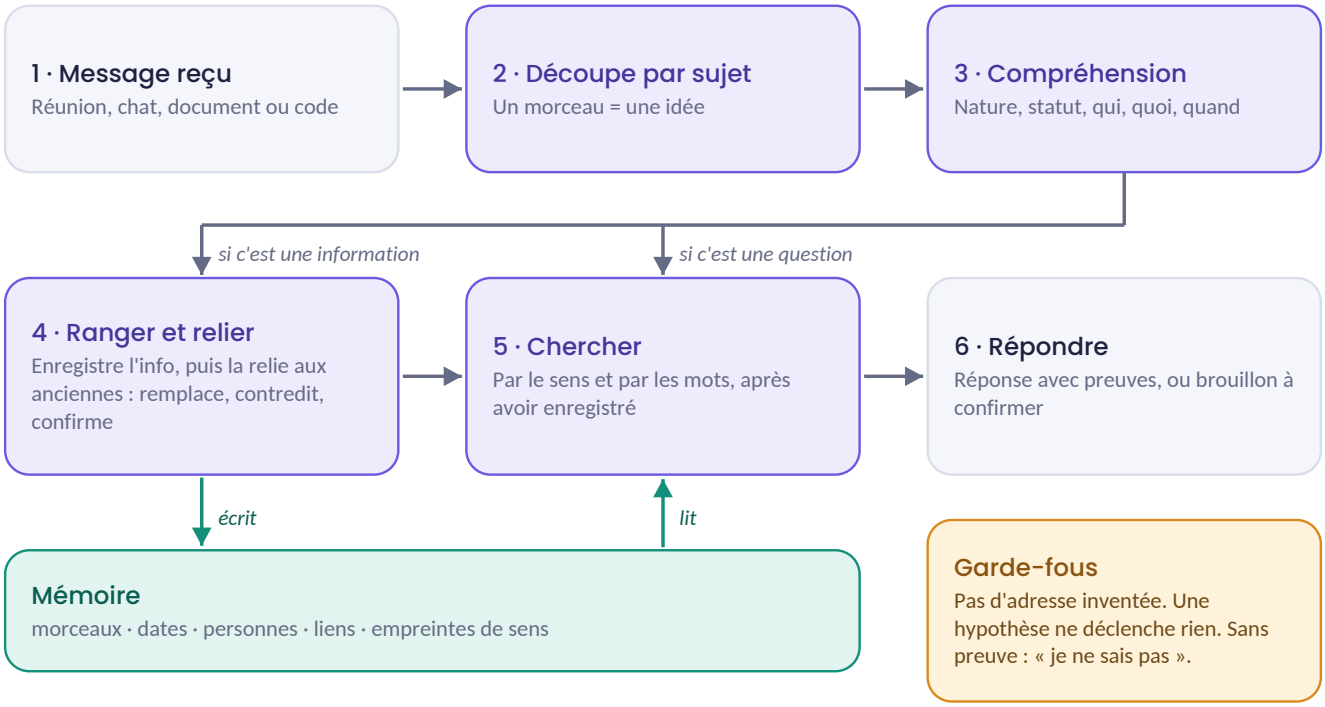
Documents et code

Le même moteur sert de recherche générale : seul le découpage change (un paragraphe cohérent, une fonction). La mémoire, les liens et la recherche restent identiques.

1 Le parcours d'un message

Voici ce qui se passe quand un message arrive. Exemple utilisé dans tout le document :

> *« Pour le projet X, on repousse le lancement à décembre. Au fait, où en est le back-end ? »*



Sur l'exemple

- **Morceau A** : « on repousse le lancement à décembre ». C'est une information (une décision). Elle est rangée en mémoire et reliée à l'ancienne date de lancement, qui passe en « remplacée ».
- **Morceau B** : « où en est le back-end ? ». C'est une question : on cherche dans la mémoire, **après** avoir enregistré A, pour que la réponse tienne compte de ce qui vient d'être dit.

2 Découper par sujet

Un morceau = la plus grande portion qui parle encore de la même chose

Documents

On regroupe les phrases voisines qui parlent de la même chose. Cinq phrases sur un même sujet : un seul morceau. Une phrase sur une voiture puis une sur un ballon : deux morceaux.

Conversations

On coupe dès que le sujet ou l'intention change, même au milieu d'une prise de parole. Dans l'exemple, une décision puis une question : deux morceaux. Un « OK, validé » très court reste collé au message précédent.

Code

Une fonction = un morceau. Ce sont de simples règles de lecture du code, sans intelligence artificielle.

Toujours : même quand un morceau regroupe plusieurs phrases, on garde chaque phrase d'origine comme **preuve**. Un gros morceau ne doit pas noyer un détail comme une date ou un nom.

3 La mémoire

Ce qu'on garde, et comment on le range pour aller vite

Pour chaque morceau, on garde

- le **texte** et la **phrase exacte** d'origine (la preuve)
- sa **nature** : décision, action, engagement, question, réponse, fait, risque, idée
- son **statut** : proposé, confirmé, annulé, remplacé
- la **date**, la **personne** qui parle, le **responsable** et l'**échéance**
- la **source** (réunion, document) et le **projet**
- des **liens** vers d'autres morceaux : remplace, contredit, confirme, répond à
- une **empreinte de sens** : une suite de nombres qui représente ce que veut dire le morceau

Comment on le range

Un cahier (base SQLite). Tout y est écrit : texte, dates, personnes, statuts, liens. Filtrer par projet ou par date est instantané, et la recherche par mots exacts est déjà intégrée.

Un index de sens (FAISS). Deux textes de sens proche ont des empreintes proches ; l'index retrouve les plus proches en quelques millisecondes. Chaque entrée renvoie au numéro du morceau dans le cahier.

Règle d'or : on n'efface jamais. Un morceau remplacé est marqué « remplacé ». L'historique reste disponible pour comparer deux réunions.

Pourquoi pas de simples fichiers JSON ? Ils sont lents à filtrer et à mettre à jour quand la mémoire grandit. Le JSON reste utile *à l'intérieur* du cahier, pour les informations supplémentaires de forme libre. Chaque morceau a deux empreintes : une **stable** (le sens du morceau seul) et une **enrichie par le contexte**. **Vérifié :** l'empreinte enrichie perd sur données réelles → la stable reste la seule active.

4 Retrouver la bonne information

Six étapes, de la question à la réponse prouvée

1	**Comprendre la demande** Un petit modèle rapide devine ce que veut la personne : répondre, comparer, faire un dossier, écrire un e-mail, créer une tâche, planifier, ou demander une précision. Il repère aussi qui, quoi, pour quand.
2	**Chercher de deux façons** Par le **sens** (retrouve les reformulations) et par les **mots exacts** (noms, dates, chiffres). Les deux listes sont fusionnées.
3	**Filtrer selon la demande** Réponse : seulement l'information en vigueur. Comparaison : l'ancienne et la nouvelle, classées par date. Dossier : tout, avec les informations remplacées signalées.
4	**Départager** Un second modèle relit la question avec chaque candidat et les classe du plus au moins pertinent.
5	**Suivre la chaîne de remplacement** Si A a été remplacé par B, puis par C, on retient C. L'historique complet reste disponible.
6	**Répondre avec preuves** Par défaut, un gabarit rédige la réponse en citant chaque affirmation : **réponse par gabarit citable par défaut ; réécriture LLM optionnelle, validée par un vérificateur**, qui renvoie toute réécriture contenant un nom ou un nombre inventé. Pas assez de preuve : « je n'ai pas assez d'information ». Pour un e-mail, le destinataire n'est retenu que s'il est clair, récent et unique ; sinon on demande.

5 Mises à jour

Vite tout de suite, en profondeur plus tard

Tout de suite (instantané)

- découper et comprendre le nouveau message
- l'enregistrer dans la mémoire
- le comparer à ses plus proches voisins et créer les liens
- marquer « remplacé » ce qui l'est

En arrière-plan (par lots, chaque nuit)

- regrouper les morceaux en fils de discussion
- reconstruire l'index de sens
- **audit de calibration** : gare aux seuils périmés ; l'audit recalibre et propose, sans jamais remplacer le modèle livré
- proposer un ré-entraînement quand assez de données ont été corrigées

C'est surtout utile pour les **messages**, qui arrivent en continu : la réaction est immédiate, le grand rangement se fait par lots, sans jamais ralentir la conversation.

6 Ce qu'on entraîne, et sur quoi

Chaque modèle a un rôle précis et se mesure séparément

Rôle	Point de départ	On l'entraîne sur…	On mesure…
Découpeur où couper	Règle de similarité entre phrases, puis petit modèle multilingue	Paires de phrases voisines « même sujet / sujet différent », fabriquées en collant des extraits de réunions différentes, + exemples annotés	Qualité des coupures
Lecteur nature, statut, qui/quoi/quand, type de demande	CamemBERT (moderncamembert-base), licence MIT vérifiée	Conversations françaises annotées : réunions publiques + dialogues synthétiques vérifiés à la main	F1 par catégorie ; recours à un LLM si « pas sûr »
Moteur de sens empreintes	Base déterministe par hachage (aucun téléchargement, aucun GPU) ; e5-base pour les vérifications en français réel ; bge-m3 jamais mesuré	Paires question / bon passage + « faux amis » (même sujet, mauvais statut, personne ou date)	Recall@K, MRR, nDCG ; score sur les faux amis. **Version fine-tunée entraînée :** gagne ses propres tests, perd le test final → base gelée conservée
Relieur remplace, contredit, confirme	Règles + garde-fous déterministes (livrés). Tête entraînée sur XNLI : branchée, mais optionnelle	Paires datées : une décision avant, une décision après, avec la bonne relation	F1 par relation, matrice de confusion
Trieur final classement	bge-reranker-v2-m3 prêt à l'emploi	Rien au départ. Entraîné seulement si les cas difficiles le justifient	Gain sur les cas difficiles
Couche « concepts » testée, désactivée	Petit réseau qui regarde tous les morceaux ensemble	Flux simulés : une info arrive, une autre la remplace	Mesurée sur données réelles en français : elle perd, donc elle reste désactivée. Preuve que les règles de jugement fonctionnent
Rédacteur réponses, dossiers	Gabarit qui cite chaque affirmation (par défaut) ; réécriture LLM optionnelle (drapeau)	Aucun entraînement	Citations exactes ; vérificateur qui rejette tout nom ou nombre inventé

Lecteur vérifié : Laya écarté (modèle de dialogue, pas un encodeur) ; CamemBERT retenu, licence MIT vérifiée.

7 Comment cela répond au sujet

Les quatre difficultés du sujet, et la pièce qui s'en occupe

Difficulté du sujet	Ce qui s'en occupe
Pertinence retrouver même avec d'autres mots	Moteur de sens + recherche par mots exacts + tri final.
Précision sémantique proposition, décision, annulation…	Lecteur de statut + « faux amis » à l'entraînement (même sujet, mauvais statut).
Contexte plusieurs réunions, dates, versions	Relieur (remplace / contredit / confirme) + chaîne de remplacement + mémoire datée et sourcée.
Intention et destinataire quelle action, pour qui	Lecteur de demandes + règle fixe pour le destinataire (clair, récent, unique) + droit de demander ou de dire « je ne sais pas ».

8 Comment on saura que ça marche

- **Retrouve-t-on la bonne information ?** Recall@K et MRR, comparés à une recherche classique par mots et à un modèle de sens non entraîné.
- **Distingue-t-on proposition et décision ?** Score par catégorie, avec une attention aux négations, aux dates et aux nombres.
- **Relie-t-on correctement ?** Score par relation et matrice de confusion (remplace / contredit / confirme).
- **Choisit-on le bon destinataire, ou demande-t-on ?** Précision, taux de faux destinataires, abstentions justifiées.
- **Les réponses sont-elles prouvées ?** Citations exactes et part d'affirmations sans preuve.

Le test décisif : la version en vigueur

On insère « lancement en décembre » (1er octobre), puis « finalement en janvier » (5 octobre), puis quelques messages sans rapport, et on demande : « quand est le lancement ? ». **Résultat mesuré :** la bonne version sort en premier dans **0,55** des cas, contre **0,25** pour une recherche classique, sur des projets jamais vus (+0,31, significatif sur les 3 tirages aléatoires testés sur 3). Le test décembre → janvier figure dans le rapport : la géométrie seule échoue, la couche de relations corrige. **Honnêtement :** l'objectif absolu de 0,90 n'est pas atteint, et sur de la parole réelle brute l'étiquetage des sujets reste non résolu (il faut plus de réunions annotées). Avec des sujets étiquetés à la main, les 7 démonstrations passent 10/10 sur de vraies réunions françaises.

9 Preuves

Montré, pas promis

Les démos passent

Les 7 démonstrations passent sur le corpus synthétique, et 10/10 sur trois vraies réunions françaises.

Tout se régénère

Chaque chiffre se régénère à partir des artefacts, avec une seule commande.

Licences vérifiées

Tous les modèles et tous les jeux de données ont une licence vérifiée.

Mesure	Résultat
Version en vigueur en premier (projets jamais vus)	0,25 → 0,55 (+0,31 ; significatif sur 3 tirages sur 3) face à la recherche classique
Objectif absolu 0,90	Non atteint
7 démonstrations	Réussies sur le corpus synthétique ; 10/10 sur trois vraies réunions françaises (sujets étiquetés à la main)
Moteur de sens fine-tuné	Gagne ses propres tests, perd le test final → base gelée conservée
Couche « concepts » / empreinte enrichie	Perd sur données réelles en français → désactivée

C'est l'exigence « protocole reproductible » du sujet, **montrée plutôt que promise**.

10 Plan et priorités

Semaine 1

- Données choisies et documentées
- Schéma d'annotation
- Recherche par mots + sens, sans entraînement : le point de départ chiffré

Semaine 2

- Entraîner le lecteur et le relieur
- Affiner le moteur de sens
- Au moins une ablation

Semaine 3

- Agent complet, dossiers, brouillons
- Démonstration en 7 scènes
- Rapport : résultats, erreurs, limites

Si le temps manque, l'ordre est : (1) mémoire + recherche hybride + lecteur + relieur ; (2) moteur de sens affiné ; (3) découpeur appris ; (4) couche « concepts » comme expérience comparée. Le cœur fonctionne sans la couche (4).

11 Limites mesurées

Ce que les mesures montrent, pas ce qu'on craignait

- **« Contredit » est la relation la plus faible.** La nouvelle matrice de confusion en montre la forme : c'est là que le relieur se trompe le plus.
- **3 questions sans réponse sur 12 laissent encore filtrer une réponse** au lieu d'un « je ne sais pas ».
- **La relation « répond à » n'est jamais produite** par le relieur livré.
- **L'étiquetage des sujets sur de la parole réelle brute** est le seul problème ouvert lié à la quantité de données : il faut plus de réunions annotées.

12 Petit lexique

Les mots techniques, en clair

Empreinte de sens (embedding)	Une suite de nombres qui représente le sens d'un texte. Deux textes de sens proche ont des empreintes proches.
Recherche par mots (BM25)	Retrouve les textes qui contiennent les mêmes mots que la question. Très bon pour les noms, dates et chiffres.
Fusion (RRF)	Mélange deux classements (par sens et par mots) en un seul, sans avoir à régler de poids.
Trieur (reranker)	Un modèle qui lit la question et un candidat ensemble pour mieux les classer.
Relieur	Compare deux morceaux et dit s'ils se confirment, se contredisent ou si l'un remplace l'autre.
Faux amis (hard negatives)	Exemples qui se ressemblent mais ne veulent pas dire la même chose : même sujet, mauvais statut, mauvaise date.
Entraîner (fine-tuning)	Reprendre un modèle déjà appris et le spécialiser sur nos propres exemples.
FAISS / SQLite	Deux outils de rangement : FAISS retrouve par proximité de sens, SQLite stocke tout le reste dans un cahier.
LLM	Modèle de langage qui rédige du texte. Ici, il est optionnel et un vérificateur contrôle ce qu'il écrit.